



HEALTH & LIFE IPS SAS

Auditor Médico Digital

Validación automatizada de Historias Clínicas y Pre-facturación
mediante Inteligencia Artificial

Equipo Predictors

Samsung Innovation Campus 2025 · 4 de agosto de 2026

Las inconsistencias se detectan demasiado tarde

Health & Life IPS SAS identifica discrepancias entre la Historia Clínica y la Pre-facturación únicamente durante la auditoría médica, cuando la factura ya fue emitida.



Glosas y rechazos

de facturación por inconsistencias no detectadas a tiempo



Reprocesos administrativos

que consumen horas de auditoría manual



Pérdida de ingresos

por procedimientos no facturados correctamente

Health & Life IPS SAS

- Historia Clínica
- Pre-facturación
- Emisión de factura



Auditoría médica posterior

Aquí es donde hoy se detectan las inconsistencias: demasiado tarde para evitar la glosa.

Un sistema híbrido de auditoría preventiva

Combina reglas de negocio determinísticas con un modelo de Inteligencia Artificial para detectar inconsistencias antes de que la factura se emita.



Motor de Reglas de Negocio

- BR-01** Detecta NO_FACTURADO y CODIGO_NO_COINCIDE
- BR-02** Servicios sin soporte clínico o sin detalle HC
- BR-03** Matriz de coherencia diagnóstico–procedimiento




Modelo de Inteligencia Artificial

9 arquitecturas de Machine Learning y Deep Learning entrenadas y comparadas de forma sistemática bajo un pipeline oficial y reproducible.

Ganador: XGBoost Hybrid

Tabular + SentenceTransformer

Arquitectura del sistema



Cinco fuentes integradas en un Master Dataset

01_pacientes.csv

300 reg.

Identificación y datos
demográficos

02_atenciones.csv

1,200 reg.

Registro de cada atención médica

03_historia_clinica_detalle.csv

3,056 reg.

Procedimientos, consultas,
tratamientos

04_prefactura.csv

2,974 reg.

Servicios y valores pre-facturados

05_cruce_validacion.csv

3,126 reg.

Resultado histórico de validación
(ground truth)



Master Dataset

3,126

registros

× 55 columnas

*Unidas por id_paciente e id_atencion, replicando el
flujo real de la operación.*

Calidad de datos: base sólida desde el inicio

99.82%

Compleitud global

100%

Integridad referencial

0

Filas duplicadas

0

Registros perdidos en la
integración

Los únicos valores nulos (`id_prefactura`, `id_detalle_hc`) son intencionales: representan lógica de negocio real, ausencia de prefactura o de soporte clínico, no errores de captura.



Desafío identificado desde esta fase:

desbalance de clases — 79.24% CONSISTENTE vs. 20.76% INCONSISTENTE — que se materializaría luego en el modelado.

ASUM-DM: un proceso iterativo, de punta a punta



Metodología de naturaleza iterativa: cada fase retroalimenta a las anteriores conforme se profundiza en el conocimiento de los datos y del modelo.

Nueve arquitecturas, comparadas bajo un mismo pipeline

train_and_evaluate.py · requirements.txt reproducible · 13/13 tests automatizados

Modelos clásicos

- Random Forest calibrado
- Logistic Regression + TF-IDF
- SVM + TF-IDF

Embeddings & híbridos


- SentenceTransformer + Logistic Regression
- SentenceTransformer + SVM
- MLP híbrida (tabular + SentenceTransformer)

Boosting & Deep Learning

- CNN 1D textual real (TextVectorization + Embedding + Conv1D)
- XGBoost híbrido (tabular + texto embebido)
- LightGBM híbrido (tabular + texto embebido)

Comparativa de resultados: 9 modelos evaluados

Accuracy vs. Recall de inconsistencias — la métrica que más importa al negocio





MODELO SELECCIONADO

XGBoost Hybrid

Tabular + SentenceTransformer

0.7652

Accuracy

0.7585

Balanced Accuracy

0.7347

Macro-F1

0.7385

Recall de inconsistencias

Selection Score · 0.7408

Métrica compuesta que combina Accuracy, Balanced Accuracy, Macro-F1 y Recall de inconsistencias para evitar seleccionar un modelo que solo optimiza la accuracy global, ignorando el desbalance de clases del problema.

¿Por qué XGBoost y no LightGBM?

LightGBM Hybrid

Accuracy **0.9201**

Macro-F1 **0.7736**

Recall inconsistencias **0.6462**

Mayor accuracy y macro-F1, pero detecta menos inconsistencias reales.

XGBoost Hybrid · Seleccionado



Accuracy **0.7652**


Macro-F1 **0.7347**

Recall inconsistencias **0.7385**

Menor accuracy global, pero detecta más inconsistencias clínicas reales, prioridad del negocio.

Dejar pasar una inconsistencia real es más costoso para la auditoría que revisar una alerta que resulta ser un falso positivo.

Matriz de confusión — XGBoost Hybrid





CONCLUSIONES

- Se integraron cinco fuentes de datos heterogéneas en un Master Dataset único, consistente y con integridad referencial completa.
- Se construyó un sistema híbrido: Motor de Reglas de Negocio (BR-01, BR-02, BR-03) + modelo de IA.
- Se compararon 9 arquitecturas bajo un pipeline oficial y reproducible de entrenamiento.
- Se seleccionó XGBoost Hybrid por su mejor equilibrio entre accuracy y recall de inconsistencias clínicas.
- La solución reduce el trabajo manual del auditor, priorizando su esfuerzo en los casos de mayor riesgo.
- Queda una base técnica sólida y ejecutable: requirements.txt, pipeline oficial y suite de pruebas automatizadas.



EQUIPO PREDICTORS



Antonio García

Coordinación general,
comprensión del negocio y
documentación



Miguel Alfonso

Comprensión de datos,
relaciones y calidad



Yineth Botina

Preparación de datos, limpieza
e integración



Diego Bejarano

Modelado y desarrollo del
modelo predictivo



Johann Smith

Evaluación del modelo, tablero
de indicadores y alertas

Gracias

Samsung Innovation Campus 2025 · Health & Life IPS SAS